

Reporte Técnico

Sistema Inteligente de Auditorías de Proceso en Línea de Producción

Diplomado de Python y Análisis de Datos — Universidad Marista
Proyecto Final

1. Resumen ejecutivo

Este proyecto digitaliza la auditoría de proceso de línea de producción (EPP, uso del vernier, apego a instrucción de trabajo, matriz de polivalencia, 5S, registro de calidad, tiempo de ciclo y manejo de producto no conforme) y aplica de forma integrada estadística inferencial, Machine Learning, Deep Learning, NLP, embeddings, un asistente LLM con RAG, un agente con Tool Calling, y análisis espectral (Fourier) y multiresolución (Wavelets) sobre una señal dimensional de proceso. El resultado es una aplicación Streamlit funcional, desplegable en la nube, que convierte auditorías dispersas en decisiones de mejora continua accionables.

2. Problema

Las auditorías de piso se capturan hoy de forma dispersa (papel/hojas sueltas), sin una vista integrada que permita detectar patrones de riesgo por línea, turno u operador, anticipar auditorías con hallazgos críticos, ni consultar de forma natural los procedimientos vigentes (Instrucciones de Trabajo).

3. Objetivo general

Construir y desplegar en la nube una aplicación que digitalice la auditoría de proceso y aplique análisis de datos e inteligencia artificial de extremo a extremo para convertir esas auditorías en decisiones de mejora continua.

4. Objetivos específicos

- Digitalizar la cédula de auditoría con almacenamiento reproducible.
- Cuantificar estadísticamente el efecto de turno, línea y antigüedad del operador.
- Predecir el riesgo de una auditoría con hallazgo crítico antes de que ocurra.
- Segmentar operadores por patrón de desviación para dirigir capacitación.
- Clasificar y buscar semánticamente los comentarios libres del auditor.
- Responder preguntas de piso sobre Instrucciones de Trabajo con un asistente RAG.
- Analizar la señal dimensional en frecuencia y multiresolución.


5. Fuente y descripción de datos

Dataset sintético pero estadísticamente realista, generado con semilla fija (reproducible). Incluye **1,415 auditorías** de proceso, **40 operadores** con matriz de polivalencia y antigüedad, **5,760 lecturas** de señal dimensional de alta frecuencia (24 muestras/día en 2 líneas instrumentadas) y 6 Instrucciones de Trabajo como base documental del módulo RAG.

6. Arquitectura

Arquitectura modular en tres capas: (1) interfaz Streamlit, (2) lógica de negocio en módulos independientes de src/ — uno por bloque del diplomado — y (3) fuentes de datos (CSV + documentos de texto). Ver diagrama a continuación.

Arquitectura — Sistema Inteligente de Auditorías de Proceso



7. Ingeniería de datos (Pipeline)

Se aplicó tipado de columnas, eliminación de duplicados por audit_id (0 removidos), imputación conservadora de respuestas faltantes (0 filas, siempre a 'No OK sin acción' — nunca se asume cumplimiento), marcado de mediciones dimensionales atípicas (0) y merge con el catálogo de operadores.

8. Análisis Exploratorio de Datos (EDA)

Distribución del score de cumplimiento promedio por línea:

Línea	Score promedio
Línea 1	89.4%
Línea 2	89.0%
Línea 3	89.5%
Línea 4	89.2%

Hallazgo clave: el score promedio cae de 90.1% a 81.9% cuando un operador cubre una línea fuera de su matriz de polivalencia, concentrado en la pregunta P4.

9. Estadística

Prueba de hipótesis (turno Nocturno): Con $p=0.0000 < 0.05$, se rechaza H_0 : hay evidencia estadística de que el turno Nocturno tiene un score de cumplimiento promedio menor. Se recomienda reforzar supervisión/auditoría en ese turno.

Correlación antigüedad–cumplimiento: Correlación positiva ($r=0.150$, $p=0.0000$).

10. Series temporales

La tendencia general del score diario es **mejorando**. El peor día de la semana en promedio es **Sunday** y el mejor **Saturday**.

11. Feature Engineering

Se construyeron medias móviles (7 y 30 días), desviación estándar móvil, rezagos (lags 1, 7 y 14 días) y un componente estacional por día de la semana, listos para alimentar un modelo de forecasting supervisado del score diario.

12. Machine Learning

modelo	accuracy	precision	recall	f1	roc_auc
Baseline (mayoría)	0.619	0.0	0.0	0.0	0.5
Regresión Logística	0.61	0.49	0.556	0.521	0.628
Random Forest	0.613	0.492	0.444	0.467	0.608
Gradient Boosting	0.63	0.523	0.333	0.407	0.61
Ensemble (Voting RF+GB+LR)	0.621	0.505	0.407	0.451	0.625

Mejor modelo: **Regresión Logística**. Se aplicó validación cruzada estratificada (5-fold) y un ensemble Voting (RF+GB+LR), dentro de un Pipeline de scikit-learn que evita data leakage (el preprocesador se ajusta solo

con el set de entrenamiento).

Clustering no supervisado (K-Means + PCA) sobre el perfil de desviaciones de cada operador permite segmentar en grupos de riesgo por categoría (Seguridad, Calidad, Proceso, Personal) para dirigir capacitación específica.

13. Deep Learning

modelo	accuracy	f1	roc_auc
MLP (Deep Learning)	0.607	0.382	0.554
Regresión Logística (clásico)	0.61	0.521	0.628

Se implementó un MLP (32,16 neuronas, ReLU, Adam) comparado contra Regresión Logística sobre el mismo problema de clasificación de riesgo. No se exige que Deep Learning supere al modelo clásico; se exige implementarlo, evaluarlo y compararlo honestamente.

14. NLP y embeddings

Clasificador de severidad basado en TF-IDF sobre el comentario del auditor: Accuracy=0.726, F1 macro=0.741. Para búsqueda semántica se usa Sentence-Transformers (con fallback automático a TF-IDF+SVD si el entorno de despliegue no tiene acceso al modelo), comparado explícitamente contra el ranking TF-IDF clásico en la aplicación.

15. LLM

Se integra la API de Claude (Anthropic) con un prompt de sistema que exige responder solo en español, de forma accionable, y basarse ÚNICAMENTE en los datos entregados en el mensaje (control de alucinaciones). Se valida el formato de salida (JSON) con reintento automático, y cualquier error de red/API se captura y se muestra de forma controlada en la interfaz.

16. RAG

Pipeline completo (documentos → chunking → embeddings → índice → Top-k → contexto → respuesta con fuentes citadas → manejo explícito de 'sin evidencia') sobre las Instrucciones de Trabajo de la planta. Evaluación del retriever sobre 7 preguntas de prueba: **Recall@3 = 1.0, MRR = 1.0**.

17. Agentes

Agente tipo router + dispatcher con 6 herramientas (calculadora, predictor de riesgo, consulta estadística, consulta RAG, analizador de series y un generador de reporte como tarea multi-step). Se registran todas las llamadas (log auditable), se limita el número de pasos y se capturan errores por herramienta. **Tool Selection Accuracy = 100%** sobre 8 casos de prueba.

18. Fourier

Análisis espectral (FFT) sobre la señal dimensional de la Línea 1. Interpretación de las frecuencias/periodos dominantes:

- Periodo ≈ 7.1 días -> sugiere un ciclo SEMANAL (ritmo de producción lunes-viernes).
- Periodo ≈ 1.0 días -> sugiere un ciclo DIARIO (arranque/cierre de turno).

- Periodo ≈ 6.7 días -> sugiere un ciclo SEMANAL (ritmo de producción lunes-viernes).
- Periodo ≈ 1.17 días -> componente sin una interpretación operativa clara todavía.
- Periodo ≈ 0.88 días -> componente sin una interpretación operativa clara todavía.
- Nota: un pico espectral solo indica periodicidad, NO causalidad; se debe contrastar con el proceso real antes de tomar acciones.

19. Wavelets

Descomposición Wavelet (db4, 4 niveles). Energía por nivel: aproximación (tendencia): 82.0%, detalle nivel 4: 8.4%, detalle nivel 3: 2.7%, detalle nivel 2: 2.8%, detalle nivel 1: 4.2%. Se detectaron **57 anomalías** por energía local del detalle de nivel fino, coincidiendo con las ráfagas de desgaste de herramienta inyectadas en la simulación (validación del método).

20. Evaluación integral

La evaluación integral combina evidencia cuantitativa (métricas de ML/DL/NLP/RAG/Agentes reportadas arriba, todas recalculadas en vivo) con evidencia cualitativa (interpretación de negocio de cada hallazgo), siguiendo el principio del proyecto: qué se hizo, por qué, cómo se midió y qué valor produce.

21. Despliegue

Aplicación Streamlit desplegada en Streamlit Community Cloud. Variables sensibles (API key del LLM) gestionadas vía `*secrets*`, nunca en el repositorio. Dependencias fijadas en `requirements.txt`. El dataset sintético se autogenera en el primer arranque, sin dependencias de red obligatorias (salvo el LLM y, opcionalmente, el modelo de embeddings, ambos con manejo explícito de fallo/():contenedor).

22. Limitaciones

- El dataset es sintético; los efectos de negocio fueron inyectados deliberadamente.
- El embedding semántico puede degradarse a TF-IDF+SVD sin acceso de red al modelo.
- El LLM requiere una API key propia para operar en producción.
- El router del agente usa reglas explicables, no tool-use nativo del LLM.

23. Conclusiones

El proyecto demuestra que es posible integrar, sobre un mismo problema de negocio real, todo el recorrido del diplomado —desde el pipeline de datos hasta agentes con LLM y análisis de señales— produciendo evidencia medible (no solo mencionada) en cada bloque, y empaquetado en una aplicación funcional desplegable en la nube.

24. Trabajo futuro

- Persistencia en base de datos remota (Postgres/Supabase) en vez de CSV.
- Tool-use nativo de la API de Anthropic en reemplazo del router de reglas.
- Forecasting supervisado del score diario usando los lags ya calculados.

- Autenticación de usuarios y control de versiones de las Instrucciones de Trabajo.